

Ejercicios de práctica

Pandas (1)

DataFrames, selección, filtros y agrupación

Objetivo	Practicar la manipulación de datos tabulares mediante pandas, aplicando selección, filtrado, transformación y agrupación sobre un conjunto de datos real.
Temas	DataFrame y Series, selección de columnas, loc e iloc, máscaras booleanas, filtros combinados, columnas derivadas, groupby, agregaciones y noción básica de merge.
Modalidad	Ejercicios incompletos para resolver individualmente durante la sesión, verificando cada resultado antes de avanzar.

- Cómo trabajar: complete cada bloque marcado con ___, ejecute el código y compare con el resultado esperado antes de avanzar al siguiente ejercicio.

Regla de trabajo

- Los espacios marcados con ___ deben ser completados.
- Ejecute los ejercicios en orden: algunos se apoyan en operaciones anteriores.
- Antes de ejecutar un filtro o una agrupación, anticipe qué resultado espera obtener.
- No modifique el DataFrame original salvo cuando el ejercicio lo indique.
- Cuando se solicite una interpretación, responda en una o dos frases basadas en los datos.

Datos de trabajo

Supermarket Sales, publicado en Kaggle por Aung Pyae: 1000 ventas de tres sucursales durante tres meses de 2019. El bloque siguiente carga los datos y normaliza los nombres de las columnas. Ejecútelo tal como está: no es un ejercicio.

```
import pandas as pd
import numpy as np

url = "https://raw.githubusercontent.com/plotly/datasets/master/supermarket_Sales.csv"
data = pd.read_csv(url)

data = data.rename(columns={
    'Tax 5%': 'Tax',
    'Cost of goods sold': 'Cogs',
    'Gross margin percentage': 'Gross margin pct',
    'Customer stratification rating': 'Rating'
})

data.columns = (
    data.columns
    .str.strip()
    .str.lower()
    .str.replace(' ', '_')
)
```

Después de ejecutarlo, los nombres de las columnas quedan en minúscula y sin espacios: invoice_id, branch, city, customer_type, gender, product_line, unit_price, quantity, tax, total, date, time, payment, cogs, gross_margin_pct, gross_income y rating.

A. Conocer el DataFrame

Dimensiones, columnas y tipos de dato

1

Dimensiones del DataFrame

BÁSICO

Complete la instrucción para conocer el número de filas y de columnas.

```
print(data.___)
```

Resultado esperado: Una tupla con las dimensiones del DataFrame.

Respuesta breve: ¿cuál de los dos números corresponde a los registros y cuál a las variables?

2 Columnas, tipos y primeras filas

BÁSICO

Muestre los nombres de las columnas, el tipo de dato de cada una y las tres primeras ventas registradas.

```
print(data.__dict__)
print(data.dtypes)

data.head(3)
```

Resultado esperado: El listado de las 17 columnas, el tipo de dato de cada una y una tabla con las tres primeras ventas.

B. Seleccionar datos

Columnas, etiquetas y posiciones

3 Seleccionar varias columnas

BÁSICO

Construya un subconjunto que contenga únicamente product_line, quantity y total.

```
resultado = data[['product_line', 'quantity', 'total']]

resultado.head()
```

Resultado esperado: Un DataFrame de tres columnas y las mismas 1000 filas del conjunto original.

4 ¿Series o DataFrame?

INTERMEDIO

Antes de ejecutar, anote qué objeto devuelve cada línea. Después compruébelo.

```
print(type(data['total']))
print(type(data[['total']]))
```

Resultado esperado: Dos tipos distintos de objeto de pandas, aunque ambas líneas se refieran a la misma columna.

Respuesta breve: ¿por qué la segunda línea devuelve un DataFrame y no una Series?

.....

.....

5 loc y iloc sobre la misma celda

INTERMEDIO

Las dos instrucciones deben mostrar la línea de producto de la fila con índice 7. La primera trabaja con etiquetas y la segunda con posiciones.

```
print(data.__[7, 'product_line'])
print(data.__[7, 5])
```

Resultado esperado: El mismo valor impreso dos veces: Home and lifestyle.

Respuesta breve: ¿por qué la segunda instrucción es más frágil si cambia el orden de las columnas?

C. Filtrar filas

Máscaras booleanas y condiciones combinadas

6 Una sola condición

BÁSICO

Conserve únicamente las ventas de más de ocho unidades y cuente cuántas son.

```
maskara = data['quantity'] __ 8
resultado = data[maskara]

print(resultado.shape[0])
```

Resultado esperado: Se imprime 211.

7 Dos condiciones al tiempo

BÁSICO

Obtenga únicamente las ventas de la sucursal C cuyo total sea mayor de 300 USD.

```
maskara = (data['branch'] == __) & (data['total'] __ 300)
resultado = data[maskara]

print(resultado.shape)
```

Resultado esperado: Un DataFrame con 146 filas y todas las columnas del original.

8 Corregir un filtro por categorías

INTERMEDIO

La instrucción comentada falla porque or no funciona entre columnas de pandas. Reescriba el filtro con una sola llamada que reciba la lista de líneas de producto.

```
# Instruccion incorrecta:  
# mascara = data['product_line'] == 'Food and beverages'  
#           or 'Fashion accessories'  
  
mascara = data['product_line'].__([__, __])  
  
print(data[mascara].shape[0])
```

Resultado esperado: Se imprime 352.

9 Rango de valores y columnas elegidas

INTERMEDIO

Obtenga las ventas de las sucursales A y C cuyo total se encuentre entre 200 y 500 USD, mostrando solamente branch, product_line, quantity y total.

```
mascara = (data['branch'].__(['A', 'C'])) & (data['total'].__(200, 500))  
  
resultado = data.__[mascara, [__, __, __, __]]  
  
resultado.head()
```

Resultado esperado: Un DataFrame de cuatro columnas con 249 filas, solo de las sucursales A y C.

Respuesta breve: ¿qué ventaja tiene resolver el filtro y la selección de columnas en una sola instrucción?

.....

.....

D. Crear información nueva

Columnas derivadas sin ciclos

10 Valor de cada unidad vendida

BÁSICO

Cree la columna `valor_unitario` dividiendo el total entre la cantidad. Resuélvalo sin escribir un ciclo `for`.

```
data['valor_unitario'] = data['__'] / data['__']  
  
print(data['valor_unitario'].head(3).round(2))
```

Resultado esperado: Una nueva columna numérica; los tres primeros valores son 78.42, 16.04 y 48.65.

11 Clasificar cada venta

INTERMEDIO

Marque como volumen las ventas de seis unidades o más y como menor todas las demás.

```
data['tipo_compra'] = np.__(data['quantity'] __ 6, 'volumen', 'menor')  
  
print(data['tipo_compra'].value_counts())
```

Resultado esperado: Dos categorías: 496 ventas de volumen y 504 menores.

Respuesta breve: ¿por qué no fue necesario recorrer las filas una por una?

.....
.....

E. Agrupar para responder preguntas

El patrón grupo → variable → operación

Cada ejercicio de este bloque parte de una pregunta de negocio. Identifique primero por qué variable se agrupa, sobre qué columna se calcula y qué operación resume el grupo.

12

¿Cuánto ingreso genera cada sucursal?

BÁSICO

Complete la agrupación que responde la pregunta.

```
resumen = (  
    data  
    .groupby(____)['total']  
    .____()  
)  
  
print(resumen.round(2))
```

Resultado esperado: Tres valores, uno por sucursal; el mayor supera los 110 000 USD y los otros dos quedan muy cerca entre sí.

13

¿Cuántas facturas registra cada método de pago?

INTERMEDIO

Complete la columna sobre la que se cuenta y la operación correspondiente.

```
resumen = (  
    data  
    .groupby('payment')[____]  
    .____()  
)  
  
print(resumen)
```

Resultado esperado: Tres resultados: 344, 311 y 345 facturas.

Respuesta breve: ¿qué representa cada fila del resultado agrupado?

.....
.....

14 Varias métricas por método de pago

AVANZADO

¿Cuántas facturas, cuántas unidades y cuánto ingreso deja cada método de pago? Una sola agrupación debe entregar las tres métricas con nombres explícitos.

```
resumen = (
    data
    .groupby('payment')
    .__call__(
        facturas=('invoice_id', 'size'),
        unidades=('quantity', '__'),
        ingreso=(__, 'sum'),
    )
    .reset_index()
)

print(resumen.round(2))
```

Resultado esperado: Un DataFrame de tres filas y cuatro columnas; el pago en efectivo concentra el mayor ingreso, cercano a 112 207 USD.

F. Integrar información

Dos tablas que comparten una clave

15 **Agregar la zona de cada sucursal**

INTERMEDIO

La tabla de ventas no indica en qué zona está cada sucursal. Esa información vive en un catálogo aparte. Intégrela conservando todas las ventas.

```
sucursales = pd.DataFrame({
    'branch': ['A', 'B', 'C'],
    'zona': ['Centro', 'Norte', 'Sur']
})

resultado = data.merge(
    sucursales,
    on=____,
    how=____
)

print(resultado.shape)
resultado[['branch', 'city', 'zona', 'total']].head()
```

Resultado esperado: El mismo número de filas que data y una columna adicional con la zona.

Respuesta breve: ¿qué condición deben cumplir dos tablas para poder integrarse?

.....

.....

Reto integrador

Filtrar, agrupar, calcular, ordenar e interpretar

16

La sucursal líder entre los clientes Member

AVANZADO

Considere únicamente las ventas de clientes de tipo Member. Determine qué sucursal genera el mayor ingreso total y cuál es su ticket promedio, entendido como el ingreso dividido entre el número de facturas. Escriba el código completo: aquí no hay espacios para completar.

```
# 1. Filtrar las ventas de clientes Member
# 2. Agrupar por sucursal: numero de facturas e ingreso total
# 3. Calcular la columna ticket_promedio
# 4. Ordenar de mayor a menor ingreso
# 5. Escribir la conclusion
```

Resultado esperado: Una tabla de tres filas con el número de facturas, el ingreso y el ticket promedio de cada sucursal, ordenada de mayor a menor ingreso.

Respuesta breve: ¿qué sucursal lidera y qué indica su ticket promedio frente a las otras dos?

Cierre y pauta de revisión

Verificación final antes de entregar el cuaderno

Antes de entregar o compartir el cuaderno, verifique que el código se ejecuta de inicio a fin y que los resultados coinciden con los resultados esperados. Cuando un resultado no coincida, revise primero los nombres de las columnas, los paréntesis de cada condición y el orden de las operaciones.

Elemento	Uso esperado en los ejercicios
DataFrame	Representar datos tabulares organizados en filas y columnas.
Selección	Elegir las variables o los registros necesarios para una pregunta.
Filtro	Conservar únicamente las filas que cumplen una condición.
Columna derivada	Construir información nueva a partir de variables existentes.
groupby	Dividir los datos en grupos para calcular resúmenes.
merge	Integrar información de otra tabla mediante una clave común.

Referencias breves

- The pandas development team. pandas documentation: User Guide.
- McKinney, W. Python for Data Analysis. O'Reilly.
- Aung Pyae. Supermarket Sales (Kaggle).

Autoevaluación rápida

- ☐ 1. ¿Puedo distinguir entre una Series y un DataFrame?
- ☐ 2. ¿Puedo seleccionar filas y columnas usando loc?
- ☐ 3. ¿Puedo construir filtros con una o varias condiciones?
- ☐ 4. ¿Puedo usar groupby para responder una pregunta sobre los datos?
- ☐ 5. ¿Puedo explicar qué problema resuelve merge?